

数据挖掘期末复习大纲

基于知识库截图、期末复习提纲与已整理真题归纳

一、课程总纲：数据分析与数据挖掘

知识点：

- 数据分析：用统计分析方法处理数据、提取有用信息并形成结论，核心回答“发生了什么、为什么发生”。
- 数据挖掘：从大量、不完全、有噪声、模糊、随机的数据中，自动发现隐藏的、未知的、潜在有用的信息和知识，核心回答“还会发生什么、有哪些没发现的规律”。
- 两者关系：数据分析是基础，数据挖掘是进阶；当数据量很大、关系复杂、传统逻辑不清晰时，需要依靠算法模型发现深层规律。

例子：

- 销售日报统计本周销量下降属于数据分析；根据历史购买行为发现“买尿布的人常买啤酒”属于关联规则挖掘。
- 描述某月用户流失率属于分析；预测哪些客户下月可能流失属于数据挖掘中的预测建模。

重点：会区分概念、会举例说明数据分析和数据挖掘的差异与联系，常考判断题/简答题。

二、数据分析能力 8 等级与两阶段

知识点：

- 描述阶段（传统分析）：常规报表、即席查询、多维分析/OLAP、警报。
- 挖掘阶段（高级分析）：统计分析、预报、预测性建模、优化。
- OLAP重点：通过切片、切块、钻取、上卷、旋转等操作从多维角度查看数据。

例子：

- “上个月各地区销售额是多少”是常规报表；“为什么华东区销量下降”进入统计分析；“下个月哪些客户会流失”是预测性建模。
- 按时间从年钻取到季度、月、日，是OLAP钻取；从城市汇总到省份，是上卷。

重点：会按能力等级识别业务问题属于哪个层次，尤其注意 OLAP 与预测建模的区别。

三、数据准备与数据预处理

知识点：

- 数据准备包括数据采集、数据理解、数据选择、数据预处理、特征构造等，是建模前最重要的工作。
- 数据预处理目标：提高数据质量，使数据适合算法输入，提高模型准确性、稳定性和可解释性。
- 主要任务：数据清洗、数据集成、数据变换、数据规约。
- 数据清洗：处理缺失值、噪声、异常值、重复数据和不一致数据。
- 数据集成：合并多源数据，处理实体识别、字段冲突、单位不一致和冗余属性。

- 数据变换：标准化、归一化、编码、离散化、平滑、聚集等。
- 数据规约：降维、特征选择、抽样、聚类压缩、PCA等，在尽量保留信息的同时减少数据规模。

例子：

- 年龄缺失可用均值/中位数/模型填补；收入单位有元和万元时要统一单位；KNN使用欧氏距离前要标准化。
- PCA把100个相关特征压缩为少数主成分，属于数据规约；One-Hot编码把类别变量变成0/1向量，属于数据变换。

重点：复习提纲重点。简答题很可能要求阐述数据预处理在数据挖掘中的地位和作用。

四、离散化 Discretization

知识点：

- 定义：把连续数值映射到有限区间或类别标签，也叫分箱。
- 目的：数据规约和维规约；满足某些算法对离散属性的要求；形成概念分层；削弱奇异值影响；让知识表达更简洁。
- 关键问题：分割点个数如何确定，分割点位置如何确定。
- 常见方法：等宽分箱、等频分箱、基于熵/信息增益的监督离散化、基于聚类的离散化。

例子：

- 把年龄分为少年、青年、中年、老年，是离散化；把收入按低/中/高划分也属于分箱。
- 考试可能给一组数值，让你说明等宽分箱和等频分箱的差异。

重点：会写定义、作用、方法和分割点选择思路。

五、关联规则挖掘

知识点：

- 目标：从事务数据库中发现项集之间的共现关系，典型形式为 $A \Rightarrow B$ 。
- 支持度 support：项集在所有事务中出现的比例，衡量“频繁程度”。
- 置信度 confidence：包含A的事务中同时包含B的比例，衡量规则可靠性。
- 提升度 lift：衡量A与B是否正相关， $lift > 1$ 表示正相关， $lift = 1$ 近似独立。
- Apriori原理：频繁项集的所有非空子集一定频繁；非频繁项集的超集一定非频繁。
- FP-Growth：用FP树压缩数据库，避免大量候选项集生成。

例子：

- 1000笔订单中有200笔同时买牛奶和面包，则{牛奶,面包}支持度为20%。
- 买牛奶的300笔订单中有200笔也买面包，则规则 牛奶 $\Rightarrow$ 面包 的置信度为200/300。

重点：常考支持度、置信度、Apriori剪枝思想、强关联规则判断。

六、分类与预测

知识点：

- 分类是预测离散类别标签，回归是预测连续数值。
- 逻辑回归：名字带回归，但主要用于分类；输出类别概率。
- 决策树：用信息增益、信息增益率、基尼指数等选择划分属性；连续特征通过阈值切分。
- KNN：基于距离和多数投票，训练阶段主要保存样本，因此是惰性学习；对量纲敏感，需标准化。
- 朴素贝叶斯：基于贝叶斯公式和条件独立假设，适合文本分类等场景。
- SVM：寻找最大间隔超平面；支持向量决定分类边界；核函数处理非线性问题。
- 神经网络：前向传播得到预测，损失函数度量误差，反向传播计算梯度，优化器更新参数。
- 正则化：L1/L2用于限制模型复杂度，缓解过拟合；岭回归使用L2正则。

例子：

- 邮件垃圾/正常是分类；预测房价是回归。
- KNN中若收入范围是0-100000而年龄是0-100，欧氏距离会被收入主导，所以要标准化。

重点：真题客观题高频：交叉熵、学习率、反向传播、KNN量纲、SVM核函数、L2正则、分类评价指标。

七、聚类分析

知识点：

- 聚类属于无监督学习，不依赖预先给定的类别标签。
- K-means：给定K个中心，按距离分配样本，更新中心，重复迭代直到收敛。
- K-means优点：简单、高效、适合球状簇；局限：需指定K，对初始中心和异常值敏感，不适合非凸或密度差异大的簇。
- 层次聚类：自底向上凝聚或自顶向下分裂，可用树状图表示。
- DBSCAN：基于密度，能发现任意形状簇并识别噪声点；参数为eps和MinPts。
- 距离度量：欧氏距离、曼哈顿距离、闵可夫斯基距离等。

例子：

- 按客户购买行为自动分成高价值、价格敏感、沉默客户，是聚类应用。
- K-means不同初始中心可能得到不同结果，因此可多次初始化取较优解。

重点：简答题常考K-means思想、步骤、优缺点；客观题常考聚类无监督、初始中心影响。

八、模型评价与常见问题

知识点：

- 分类评价：准确率、精确率、召回率、F1值、混淆矩阵、ROC/AUC。
- 精确率：预测为正的样本中真正为正的的比例；召回率：实际为正的样本中被找回的比例。

- F1值：精确率和召回率的调和平均，适合需要兼顾二者的场景。
- 回归评价：MSE、RMSE、MAE、 R^2 。
- 过拟合：训练集表现好、测试集表现差；欠拟合：训练和测试表现都差。
- 处理过拟合：增加数据、正则化、剪枝、交叉验证、早停、降低模型复杂度。

例子：

- 疾病筛查更重视召回率，宁愿多报也要尽量找出患者；垃圾短信拦截更要平衡精确率和召回率。
- 训练准确率99%、测试准确率65%，通常是过拟合。

重点：重点掌握混淆矩阵中TP/FP/TN/FN，以及准确率、精确率、召回率、F1的含义。